# US Accidents Report

Mattia Marcellini

March 2026

## 1 Introduction

Questo progetto consisteva nel predirre la severità degli incidenti avvenuti negli Stati Uniti tramite l'utilizzo di modelli adatti a Multi-Class Classification. Il mio approccio al problema è stato:

- Analisi e scelta delle feature più rilevanti.
- Analisi dei pesi iniziali del modello e training di modelli diversi.
- Ensemble dei due modelli con performance migliori.

## 2 Analisi del Problema:

Il dataset fornito contiene circa 7.7 milioni di record relativi a incidenti stradali verificatisi in 49 stati degli Stati Uniti. Ogni osservazione è descritta da 47 variabili che includono informazioni temporali, geografiche, meteorologiche e infrastrutturali. L'obiettivo del progetto consiste nella previsione della variabile target `Severity`, che rappresenta la gravità dell'incidente su una scala da 1 a 4, dove il valore 4 indica un impatto significativo sul traffico.

Prima di procedere con la modellazione, è necessario affrontare alcune criticità strutturali del dataset:

1. **Forte sbilanciamento delle classi (class imbalance).** La distribuzione della variabile `Severity` risulta fortemente sbilanciata: gli incidenti di gravità elevata (livello 4) e di gravità leggere (livello 1) rappresentano una porzione significativamente inferiore rispetto agli eventi di gravità moderata (Livello 2 o 3). Tale squilibrio può indurre i modelli di classificazione a privilegiare le classi maggioritarie, compromettendo la capacità di individuare correttamente gli eventi più critici. Di conseguenza, l'accuratezza globale non costituisce una metrica sufficiente, rendendo necessario l'utilizzo di metriche più robuste come F1-score e recall per la classe minoritaria.

2. **Elevata dimensionalità e ridondanza delle feature.** Le 47 variabili includono numerosi attributi correlati tra loro (ad esempio variabili temporali derivate, condizioni meteorologiche e indicatori booleani relativi all'infrastruttura stradale). La presenza di feature altamente correlate o ridondanti può aumentare la complessità del modello, introdurre rumore e favorire fenomeni di overfitting. Risulta pertanto necessaria una fase strutturata di analisi e selezione delle feature.

3. **Presenza di valori mancanti (NaN).** Diverse variabili, in particolare quelle legate alle condizioni meteorologiche o ambientali, presentano valori mancanti. L'elevata numerosità del dataset non elimina il problema, poiché la distribuzione non uniforme dei NaN può introdurre bias sistematici. È quindi necessario adottare strategie adeguate per la gestione dei dati mancanti.

4. **Elevata numerosità del dataset e costi computazionali.** La presenza di milioni di osservazioni comporta un significativo costo computazionale sia in termini di memoria sia di tempo di addestramento. Ciò richiede una fase preliminare di ottimizzazione del preprocessing.

## 3 Pre-Processing

Il Pre-Processing è stata una parte fondamentale del progetto per garantire al modello feature affidabili e non ridondanti.

Il primo passaggio è stato la rimozione di feature inutili: Turning_Loop con tutti valori false, Wind_Chill(F) correlata a Tempreature(F), Country essendo sempre US e così via. A queste si aggiungono anche le feature ritenute inutili dal primo modello che causavano solo rumore.

Dalle variabili Start_Time e End_Time sono state ricavate la durata, l'ora di inizio, il mese con un encoding ciclico, il momento dela giornata (morning rush, etc..) e se fosse un periodo di vacanza.

Weather_Condition è stata divisa in due variabili:

- group_weather che descrive la condizione metereologica ed è composta da 8 categorie.

- weather_intensity che descrive l'intensità del meteo da 0 a 3 basata sugli aggettivi usati nella variabile originale.

Le strade sono state classificate in base alla tipologia e divise in categorie.

La descrizione è stata analizzata e sono state estratte le parole più frequenti/rilevanti e trasformate in categorie booleane.

Le variabili cicliche, quali la direzione del vento o le componenti temporali (mesi), sono state trasformate mediante encoding sinusoidale (sin/cos) al fine di preservarne la natura periodica.

La variabile Source è stata resa categorica data la sua correlazione con Severity.

Ad alcune variabili come durata o lunghezza della descrizione sono state applicate delle trasformazioni logaritmiche per ridurre l'influenza degli outliers.

Infine per catturare pattern spaziali latenti non immediatamente evidenti dalle sole coordinate geografiche, è stato applicato un algoritmo di clustering geografico basato su K-Means.

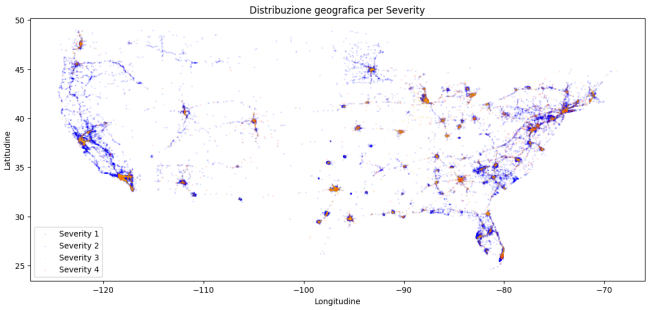


Figure 1: Clusters with severity of accidents

In particolare, dopo aver suddiviso il dataset in training, validation e test set, il modello K-Means è stato addestrato esclusivamente su un sottoinsieme di 200000 osservazioni appartenenti al training set, utilizzando come variabili di input le coordinate geografiche (latitudine e longitudine). Il numero di cluster è stato fissato a $K = 10$, selezionato empiricamente come compromesso tra granularità spaziale e stabilità dei gruppi.

Una volta appresi i centroidi sul training set, il modello è stato utilizzato per assegnare ciascuna osservazione di training, validation e test al cluster geografico più vicino, generando così una nuova feature categorica denominata `Geo_cluster`.

# 4 Modello

Tra i modelli utilizzati è stato impiegato un classificatore basato su LightGBM, algoritmo di gradient boosting su alberi decisionali particolarmente efficiente su dataset di grandi dimensioni e con feature eterogenee.

È stato impostato un learning rate pari a 0.01 e un numero elevato di stimatori (`n_estimators = 20000`), adottando quindi una strategia di boosting conservativa caratterizzata da aggiornamenti piccoli ma numerosi, al fine di migliorare la capacità di generalizzazione. Durante il training è stato poi applicato early stopping.

Il parametro `num_leaves = 255` consente la costruzione di alberi relativamente complessi, in grado di catturare interazioni non lineari tra le feature. Per mitigare il rischio di overfitting, sono stati introdotti meccanismi di regolarizzazione e campionamento: `subsample = 0.8` e `colsample_bytree = 0.8` permettono rispettivamente il campionamento casuale delle osservazioni e delle feature ad ogni iterazione di boosting, mentre i termini di regolarizzazione L1 e L2 (`reg_alpha = 0.1`, `reg_lambda = 0.1`) penalizzano modelli eccessivamente complessi.

Ulteriori vincoli strutturali sono stati imposti tramite `min_child_samples = 50` e `min_child_weight = 1e-3`, al fine di evitare la creazione di nodi foglia con un numero troppo ridotto di osservazioni o con peso informativo trascurabile.

La combinazione di tali scelte consente di bilanciare capacità espressiva e controllo della varianza, risultando particolarmente adatta a un dataset ad alta dimensionalità e caratterizzato da class imbalance.

# 5 Esperimenti

Nel corso della fase sperimentale sono stati valutati diversi modelli al fine di individuare la soluzione più efficace. In particolare, oltre al modello LightGBM, sono stati testati un classificatore CatBoost, una rete neurale Multi-Layer Perceptron (MLP) standard e una variante con connessioni residue (Residual MLP), nonché un approccio ensemble basato sulla combinazione delle predizioni di CatBoost e LightGBM e un altro ensemble basato su Residual MPL e LightGBM.

CatBoost, grazie alla gestione nativa delle variabili categoriali e al meccanismo di ordered boosting, ha mostrato prestazioni comparabili a quelle di LightGBM. Invece, l'MLP e la sua versione residuale hanno evidenziato una buona capacità di modellare relazioni non lineari, ma con una maggiore sensibilità alla scelta degli iperparametri e tempi di addestramento più elevati con performance al di sotto degli altri modelli.

I due ensemble sono stati implementati tramite soft voting sulle probabilità predette. Tuttavia, l'analisi delle metriche di valutazione ha mostrato che i due modelli generavano predizioni altamente correlate con LightGBM. D'altronde i pesi tendevano sempre a preferire quelli del modello migliore.

Alla luce di tali risultati, LightGBM è stato selezionato come modello finale, in quanto ha garantito le migliori prestazioni complessive, un buon compromesso tra accuratezza e robustezza e un costo computazionale

Table 1: Resultatui ottenuti sul test set, Il miglior modello è **evidenziato**

| Model | Accuracy | Precision | Recall | F1 score |
|---|---|---|---|---|
| **LightGBMClassifier** | 0.94 | 0.80 | 0.81 | 0.80 |
| CatBoost | 0.93 | 0.76 | 0.83 | 0.79 |
| MLP | 0.85 | 0.57 | 0.89 | 0.64 |
| Residual MLP | 0.86 | 0.57 | 0.91 | 0.65 |
| Ensemble CatBoost-LGBM | 0.94 | 0.80 | 0.81 | 0.80 |
| Ensemble ResidualMLP-LGBM | 0.93 | 0.79 | 0.82 | 0.80 |

inferiore rispetto alle alternative considerate.

# 6 Risultati e Discussione

I risultati sperimentali mostrano che il modello LightGBM selezionato è in grado di fornire prestazioni solide e stabili su training, validation e test set, confermando una buona capacità di generalizzazione. Le metriche di valutazione considerate includono accuracy, precision, recall e macro F1-score, al fine di tenere conto del marcato sbilanciamento tra le classi della variabile `Severity`.

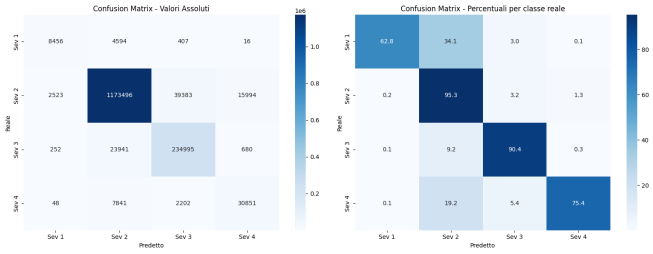


Figure 2: Confusion Matrix

In particolare, il modello ha ottenuto un'accuracy pari a *[0.94]* sul test set, accompagnata da un macro F1-score di *[0.80]*. L'analisi per classe evidenzia come le performance siano significativamente migliori sulle classi maggioritarie, mentre le classi minoritarie (Severity 1 e Severity 4) presentano un recall inferiore, coerentemente con la distribuzione sbilanciata del dataset. Tuttavia, rispetto ai modelli alternativi testati, LightGBM garantisce un miglior compromesso tra precision e recall anche per le classi più rare.

L'analisi della matrice di confusione mostra che gli errori più frequenti si verificano tra classi 1 e 4 che vengono predette come classe 2 a causa del forte sbilanciamento delle classi. Nonostante ciò riesce comunque a predirre correttamente le classi con un'elevata Accuracy.

Entrambi i modelli con embedding dei pesi hanno ottenuto risultati molto simili a quelli di LightGBM anche perchè i pesi sono tarati a favorire la predizione di LightGBM.

# 7 Conclusioni:

Il modello formato dal classificatore **LGBM** si è rivelato il migliore per complessità computazionale e performance.

# 8 Fonti


- Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, Tie-Yan Liu, *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*, 2017. Link
- Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, Andrey Gulin, *CatBoost: unbiased boosting with categorical features*, 2019. Link